

LAPORAN DESIGN RISET

Analisis Faktor yang Berhubungan dengan Kredit Macet (NPL) pada Pembiayaan Gadai Kendaraan

Dokumen metodologi dan rancangan analisis statistik

Komponen	Rancangan
Pendekatan	Kuantitatif
Desain	Observasional retrospektif
Unit analisis	Satu transaksi pembiayaan gadai kendaraan
Outcome	NPL (binary: 0/1)
Metode utama	Binary Logistic Regression
Variabel kandidat X	8 variabel: STNK, pekerjaan, merk, usia, pajak, pinjaman, LTV maximum, zona LTV
Sumber rancangan	Workbook request Mufti + sheet info dan pengembangan variabel LTV

Versi rancangan: September 2026

Ringkasan Eksekutif

Penelitian dirancang untuk menganalisis karakteristik yang berhubungan dengan kejadian Non-Performing Loan (NPL) pada pembiayaan gadai kendaraan. Outcome penelitian adalah variabel biner NPL, sedangkan kandidat prediktor terdiri dari kepemilikan STNK, pekerjaan, merk kendaraan, usia kendaraan, status pajak, besaran pinjaman pokok awal, LTV maximum (ltv_max), dan zona LTV (zona_ltv).

Metode utama adalah binary logistic regression. Analisis dilakukan bertahap mulai dari audit dan validasi data, analisis deskriptif, analisis bivariat, pengembangan beberapa spesifikasi model, pemeriksaan multikolinearitas dan asumsi, evaluasi diskriminasi serta kalibrasi, hingga sensitivity analysis.

Catatan metodologis utama: penelitian observasional ini lebih tepat menggunakan istilah “berhubungan dengan” atau “berasosiasi dengan” daripada menyatakan bahwa variabel tertentu secara kausal “menyebabkan” NPL. Selain itu, informasi yang baru muncul setelah pinjaman berjalan tidak boleh digunakan sebagai prediktor apabila tujuan akhirnya adalah prediksi risiko pada saat origination.

Rancangan juga memisahkan representasi LTV menjadi ltv_max sebagai batas maksimum LTV dan zona_ltv sebagai kategori/rentang LTV. Keduanya tidak otomatis dimasukkan bersamaan; spesifikasi model akan dipilih berdasarkan definisi bisnis, korelasi/multikolinearitas, kecocokan model, dan interpretabilitas.

1. Latar Belakang dan Rasional Penelitian

Pembiayaan gadai kendaraan menghadapi risiko keterlambatan dan kegagalan pembayaran. Untuk kepentingan manajemen risiko, penting untuk mengetahui apakah karakteristik nasabah, kendaraan, struktur pinjaman, serta karakteristik Loan-to-Value memiliki hubungan dengan status NPL.

Dataset penelitian memiliki outcome NPL yang dapat direpresentasikan sebagai 0/1 sehingga regresi logistik merupakan metode yang sesuai untuk mengestimasi hubungan antara sejumlah variabel independen dan probabilitas terjadinya NPL.

Rancangan awal diperluas dengan memasukkan ltv_max dan zona_ltv. Penambahan kedua variabel ini penting karena tingkat pembiayaan terhadap nilai jaminan merupakan komponen yang secara konseptual berkaitan dengan struktur risiko pembiayaan. Namun, bentuk hubungan dan potensi redundansi antarvariabel harus diuji secara empiris.

2. Tujuan Penelitian

2.1 Tujuan Umum

Menganalisis faktor-faktor yang berhubungan dengan kejadian kredit macet (NPL) pada pembiayaan gadai kendaraan.

2.2 Tujuan Khusus

- Mengukur proporsi NPL pada populasi pembiayaan yang diteliti.
- Mendeskripsikan karakteristik nasabah, kendaraan, dan pembiayaan.
- Menganalisis hubungan kepemilikan STNK, pekerjaan, merk, usia kendaraan, status pajak, dan besaran pinjaman dengan NPL.
- Menganalisis hubungan ltv_max dengan NPL.
- Menganalisis hubungan zona_ltv dengan NPL.
- Mengestimasi Odds Ratio (OR) dan 95% Confidence Interval.
- Menguji apakah hubungan kandidat prediktor tetap terlihat setelah pengendalian simultan melalui regresi logistik.
- Membandingkan spesifikasi model dengan dan tanpa informasi LTV.
- Mengevaluasi discrimination, calibration, goodness-of-fit, dan stabilitas model.
- Menyusun implikasi untuk segmentasi dan mitigasi risiko pembiayaan.

3. Pertanyaan Penelitian

- Apakah kepemilikan STNK berhubungan dengan NPL?
- Apakah pekerjaan berhubungan dengan NPL?
- Apakah merk kendaraan berhubungan dengan NPL?
- Apakah usia kendaraan berhubungan dengan NPL?
- Apakah status pajak berhubungan dengan NPL?
- Apakah besaran pinjaman pokok awal berhubungan dengan NPL?
- Apakah Itv_max berhubungan dengan NPL?
- Apakah zona_itv berhubungan dengan NPL?
- Setelah dikontrol bersama, variabel mana yang tetap menunjukkan asosiasi dengan NPL?
- Apakah penambahan informasi LTV memperbaiki performa model?

4. Hipotesis Penelitian

H1: Terdapat hubungan antara kepemilikan STNK dan NPL.

H2: Terdapat hubungan antara pekerjaan dan NPL.

H3: Terdapat hubungan antara merk kendaraan dan NPL.

H4: Usia kendaraan berhubungan dengan NPL.

H5: Terdapat hubungan antara status pajak dan NPL.

H6: Besaran pinjaman pokok awal berhubungan dengan NPL.

H7: Itv_max berhubungan dengan NPL.

H8: zona_itv berhubungan dengan NPL.

5. Desain Penelitian

Komponen	Rancangan
Pendekatan	Kuantitatif
Jenis desain	Observasional retrospektif
Unit analisis	Satu transaksi/pinjaman gadai kendaraan
Variabel dependen	NPL, binary 0/1
Variabel independen	8 kandidat X
Analisis utama	Binary Logistic Regression
Analisis pendukung	Deskriptif, bivariat, effect size, diagnostic, discrimination, calibration
Validasi	Temporal validation bila model digunakan untuk prediksi masa depan

5.1 Populasi dan Unit Analisis

Populasi penelitian adalah seluruh transaksi pembiayaan gadai kendaraan yang memenuhi kriteria periode dan definisi populasi pada dataset. Unit analisis adalah satu transaksi/pinjaman. Struktur data harus diaudit untuk memastikan tidak terdapat duplikasi satu pinjaman yang dapat membuat satu unit analisis muncul lebih dari sekali.

5.2 Periode dan Cut-off Date

Penelitian wajib menetapkan tanggal cut-off observasi. Hal ini penting karena Days Late dan status pembiayaan dapat berubah seiring waktu. Sebaiknya dituliskan secara eksplisit: transaksi berasal dari periode penelitian tertentu, kemudian status NPL diamati sampai tanggal cut-off yang ditentukan.

6. Definisi Operasional Variabel

Kode	Variabel / Kolom	Jenis	Definisi / coding
Y	NPL	Binary	1 = NPL; 0 = tidak NPL
X1	kondisi_name	Nominal	Kepemilikan STNK; A/N sendiri vs A/N orang lain
X2	pekerjaan	Nominal	Kategori pekerjaan nasabah
X3	merk	Nominal	Merk kendaraan
X4	Usia Kendaraan_2(thn)	Rasio	Usia kendaraan dalam tahun
X5	pajak	Nominal/Binary	Pajak aktif vs tidak aktif
X6	pinjaman_pokok_awal	Rasio / kategori	Nominal pokok pinjaman awal
X7	ltv_max	Rasio	Batas maksimum Loan-to-Value sesuai kebijakan/karakteristik pembiayaan
X8	zona_ltv	Kategorik	Zona/rentang LTV

6.1 Definisi Outcome NPL

Berdasarkan rancangan penelitian, NPL didefinisikan ketika Days Late > 30 hari dan status gadai berada pada kondisi Berjalan atau Proses Lelang. Pinjaman Lunas tidak dikategorikan NPL sesuai definisi tersebut.

Secara logika:

NPL = 1 jika (Days Late > 30) AND (status = Berjalan atau Proses Lelang). Selain kondisi tersebut NPL = 0.

Definisi tersebut harus divalidasi terhadap kolom NPL aktual. Setiap mismatch antara NPL aktual dan NPL hasil formula harus dilaporkan sebelum analisis inferensial.

6.2 Perbedaan LTV, ltv_max, dan zona_ltv

Actual LTV menggambarkan rasio pembiayaan aktual terhadap nilai jaminan. ltv_max merepresentasikan batas maksimum LTV yang diizinkan atau digunakan oleh kebijakan/produk, sedangkan zona_ltv merepresentasikan pengelompokan/rentang LTV. Karena keduanya dapat berkaitan erat dengan actual LTV, hubungan antarvariabel harus diaudit sebelum dimasukkan ke model yang sama.

7. Kerangka Konseptual

Secara konseptual penelitian memodelkan probabilitas NPL sebagai fungsi dari karakteristik nasabah, karakteristik kendaraan, dan karakteristik pembiayaan:

$$P(NPL = 1) = f(\text{STNK, Pekerjaan, Merk, Usia Kendaraan, Pajak, Pinjaman Pokok Awal, ltv_max, zona_ltv})$$

Kerangka ini bersifat associational/predictive. Untuk menyatakan hubungan kausal diperlukan desain dan asumsi tambahan yang tidak otomatis tersedia dari data observasional retrospektif.

8. Data Preparation dan Quality Control

8.1 Audit Struktur Data

- Periksa jumlah baris dan kolom.
- Identifikasi unique transaction ID dan duplicate.
- Periksa tipe data numerik, kategorik, dan tanggal.
- Periksa nilai kosong, nilai tidak wajar, dan inkonsistensi kategori.
- Periksa rentang usia kendaraan, pinjaman, LTV, dan Days Late.
- Periksa konsistensi antara tanggal gadai, jatuh tempo, pembayaran, dan penarikan.

8.2 Missing Value

Setiap variabel dibuat profil missing: N, jumlah missing, dan persentase missing. Missing pada pekerjaan perlu mendapat perhatian khusus karena proporsinya dapat besar dan complete-case analysis berpotensi mengubah populasi analisis.

Strategi yang disarankan adalah membuat model tanpa pekerjaan dan model dengan pekerjaan pada subset yang memiliki informasi pekerjaan, lalu membandingkan kestabilan estimasi variabel lainnya.

8.3 Category Consolidation

Pekerjaan dan merk dapat memiliki banyak kategori. Kategori yang sangat jarang dapat menghasilkan standard error besar, confidence interval lebar, atau separation. Konsolidasi kategori harus didasarkan pada kesamaan makna bisnis, bukan sekadar mengejar signifikansi statistik.

9. Rencana Analisis Statistik

9.1 Analisis Deskriptif

Variabel kategorik: frequency, percentage, jumlah NPL, dan NPL rate. Variabel numerik: N, mean, median, standard deviation, minimum, maximum, Q1, Q3, dan IQR.

9.2 Analisis Bivariat

Kategorik vs NPL menggunakan Chi-Square atau Fisher's Exact Test sesuai expected count. Effect size dilaporkan menggunakan Odds Ratio dengan 95% CI; Cramer's V dapat digunakan untuk kekuatan asosiasi pada tabel kategorik multi-level.

Numerik vs NPL dapat dibandingkan menggunakan t-test jika asumsi parametrik terpenuhi atau Mann-Whitney U bila distribusi tidak sesuai. Namun, untuk inferensi multivariat, bentuk numerik variabel akan diuji langsung melalui logistic regression.

10. Spesifikasi Model Penelitian

10.1 Model Statistik Dasar

Karena Y adalah binary, model utama adalah binary logistic regression.

$$\text{logit}[P(\text{NPL}=1)] = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k$$

dengan $\text{logit}(p) = \ln[p/(1-p)]$. Koefisien β ditransformasikan menjadi Odds Ratio: $OR = \exp(\beta)$.

10.2 Model 0 — Null Model

Model hanya berisi intercept. Digunakan sebagai baseline untuk likelihood ratio test dan perbandingan model.

10.3 Model 1 — Core Risk Model

$$\text{NPL} \sim \text{STNK} + \text{Pekerjaan} + \text{Merk} + \text{Usia Kendaraan} + \text{Pajak} + \text{Pinjaman Pokok Awal}$$

Model ini merepresentasikan rancangan inti sebelum memasukkan informasi LTV.

10.4 Model 2 — Core + Itv_max

$$\text{NPL} \sim \text{STNK} + \text{Pekerjaan} + \text{Merk} + \text{Usia Kendaraan} + \text{Pajak} + \text{Pinjaman Pokok Awal} + \text{Itv_max}$$

10.5 Model 3 — Core + zona Itv

$$\text{NPL} \sim \text{STNK} + \text{Pekerjaan} + \text{Merk} + \text{Usia Kendaraan} + \text{Pajak} + \text{Pinjaman Pokok Awal} + \text{zona_Itv}$$

10.6 Model 4 — Full Candidate Model

$NPL \sim STNK + Pekerjaan + Merk + Usia\ Kendaraan + Pajak + Pinjaman\ Pokok\ Awal + Itv_max + zona_Itv$

Model 4 hanya digunakan jika audit konseptual dan diagnostik menunjukkan bahwa Itv_max dan $zona_Itv$ membawa informasi berbeda serta tidak menimbulkan masalah multikolinearitas yang tidak dapat diterima.

11. Coding dan Reference Category

Variabel kategorik menggunakan dummy/one-hot encoding. Label encoding numerik tidak boleh digunakan untuk variabel nominal karena dapat menciptakan urutan artifisial.

Variabel	Reference awal yang disarankan	Catatan
STNK	A/N SENDIRI	A/N ORANG LAIN menjadi dummy
Pajak	Pajak Aktif	Tidak Aktif menjadi dummy
Merk	Kategori dengan volume terbesar / relevan	Kategori rare dapat digabung
Pekerjaan	Kategori dengan volume terbesar / substantif	Perlu konsolidasi
zona_Itv	Zona LTV terendah / baseline bisnis	Dummy; jangan dianggap interval otomatis

Untuk pinjaman, dua spesifikasi dapat digunakan: nilai rupiah continuous dan kategori bisnis. Spesifikasi continuous membantu menjaga informasi, sedangkan kategori membantu interpretasi kebijakan.

12. Model Diagnostics

12.1 Multikolinearitas

Periksa correlation matrix untuk numerik dan VIF sebagai indikator diagnostik. Perhatian khusus diberikan pada hubungan antara pinjaman, LTV, Itv_max , dan $zona_Itv$.

12.2 Linearity in the Logit

Untuk variabel numerik, evaluasi apakah hubungan dengan log-odds NPL cukup linear. Jika tidak, pertimbangkan spline atau transformasi. Usia kendaraan tidak boleh otomatis diasumsikan linear.

12.3 Separation

Periksa complete atau quasi-complete separation, terutama pada pekerjaan dan merk dengan kategori langka. Jika ditemukan, lakukan konsolidasi kategori atau pertimbangkan penalized logistic regression sebagai sensitivity analysis.

12.4 Influential Observations

Evaluasi observasi yang sangat memengaruhi koefisien atau likelihood, terutama bila terdapat kombinasi kategori langka dan outcome NPL yang ekstrem.

13. Evaluasi Performa Model

Dimensi	Ukuran	Tujuan
Fit	Likelihood Ratio Test	Menguji peningkatan model terhadap null/ model nested
Parsimony	AIC, BIC	Membandingkan fit dengan kompleksitas
Explained variation	McFadden / Nagelkerke Pseudo R^2	Ringkasan variasi yang dijelaskan
Discrimination	ROC-AUC	Kemampuan membedakan NPL vs non-NPL
Imbalance-aware	PR-AUC	Evaluasi performa pada outcome minoritas

Dimensi	Ukuran	Tujuan
Classification	Sensitivity, specificity, precision, F1	Kinerja pada threshold tertentu
Calibration	Calibration curve, Brier Score	Kesesuaian probabilitas prediksi dengan kejadian aktual

Accuracy tidak boleh menjadi satu-satunya ukuran karena proporsi NPL dapat jauh lebih kecil dibandingkan non-NPL.

14. Sensitivity Analysis

14.1 Representasi LTV

Bandingkan model dengan ltv_max, model dengan zona_ltv, dan model dengan keduanya jika layak.

14.2 Pekerjaan Missing

Bandingkan model tanpa pekerjaan dengan model yang memasukkan pekerjaan pada subset tersedia. Perubahan besar pada koefisien dapat menunjukkan sensitivity terhadap missingness/selection.

14.3 Bentuk Usia Kendaraan

Bandingkan usia sebagai continuous dengan bentuk non-linear atau kategori bila pola data mendukung.

14.4 Bentuk Pinjaman

Bandingkan pinjaman continuous dengan kategori < Rp1 juta, Rp1–2 juta, dan > Rp2 juta bila kategori tersebut sesuai dengan konteks bisnis dan distribusi data.

15. Pencegahan Data Leakage

Jika tujuan penelitian berkembang menjadi credit scoring saat origination, predictor hanya boleh menggunakan informasi yang tersedia sebelum atau pada saat keputusan pembiayaan. Variabel yang merupakan konsekuensi setelah pencairan, seperti Days Late, pembayaran terakhir, status lelang, atau pembayaran pasca-pencairan, digunakan untuk membentuk outcome atau evaluasi, bukan sebagai X.

Prinsipnya:

Informasi sebelum/ketika kredit diberikan → kandidat X; kejadian setelah kredit berjalan → pembentukan Y / monitoring outcome.

Hal ini penting agar performa model tidak tampak tinggi secara artifisial karena model menggunakan informasi yang baru diketahui setelah masalah kredit terjadi.

16. Jika Penelitian Dikembangkan Menjadi Predictive Risk Model

Analisis explanatory dan predictive harus dibedakan. Jika model dimaksudkan untuk memprediksi transaksi masa depan, gunakan temporal validation bila memungkinkan.

Contoh skema: transaksi periode awal digunakan sebagai training, periode berikutnya sebagai validation, dan periode paling akhir sebagai test. Random split dapat menjadi tambahan, tetapi tidak sebaik validasi temporal untuk mensimulasikan penggunaan di masa depan.

Untuk model prediktif, laporkan out-of-sample ROC-AUC, PR-AUC, Brier Score, calibration, confusion matrix pada threshold yang dipilih, dan stabilitas performa antarperiode.

17. Rencana Tabel dan Grafik Laporan

Output	Isi
Tabel 1	Karakteristik seluruh transaksi

Output	Isi
Tabel 2	Distribusi NPL
Tabel 3–10	NPL rate berdasarkan masing-masing kandidat X
Tabel 11	Hasil analisis bivariat
Tabel 12–15	Hasil Model 1–4
Tabel 16	Perbandingan performa model
Gambar 1	Distribusi NPL
Gambar 2	NPL rate per kategori
Gambar 3	Hubungan usia kendaraan dengan NPL
Gambar 4	NPL rate menurut zona LTV
Gambar 5	ROC Curve
Gambar 6	Calibration Curve

18. Pedoman Interpretasi

Hasil tidak boleh ditentukan hanya berdasarkan p-value. Interpretasi harus mempertimbangkan statistical significance, magnitude/effect size, precision melalui 95% CI, dan business relevance.

Contoh: OR = 1,40 dengan 95% CI 1,20–1,65 dapat diinterpretasikan sebagai odds NPL sekitar 40% lebih tinggi pada kelompok tersebut dibandingkan reference group, setelah variabel lain dalam model dikontrol. Pernyataan ini tidak sama dengan menyatakan bahwa variabel tersebut menyebabkan NPL meningkat 40%.

Dengan ukuran sampel besar, perbedaan kecil dapat menghasilkan p-value sangat kecil. Karena itu OR, confidence interval, NPL rate absolut, dan implikasi bisnis harus dibaca bersama.

19. Aturan Pemilihan Model Final

Model final tidak dipilih hanya karena memiliki jumlah variabel signifikan paling banyak. Pemilihan mempertimbangkan:

- Kesesuaian dengan tujuan penelitian.
- Ketersediaan variabel pada saat origination bila digunakan untuk prediksi.
- Tidak adanya data leakage.
- Kualitas data dan tingkat missing.
- Tidak adanya multikolinearitas yang bermasalah.
- Stabilitas koefisien dan confidence interval.
- Goodness-of-fit dan perbandingan AIC/BIC.
- Discrimination dan calibration.
- Interpretabilitas untuk kebutuhan bisnis.
- Hasil sensitivity analysis.

20. Keterbatasan yang Harus Dicantumkan

- Desain observasional tidak otomatis membuktikan kausalitas.
- Definisi NPL berbasis status pada cut-off date dapat berbeda dari definisi ever-NPL sepanjang lifecycle.
- Missing pekerjaan yang besar dapat menyebabkan selection bias pada model yang memasukkan pekerjaan.
- Kategori pekerjaan/merk yang terlalu banyak dapat menyebabkan instability atau separation.
- LTV, ltv_max, dan zona_ltv berpotensi berkorelasi sehingga perlu diagnostic.

- Jika outcome dan predictor berasal dari waktu yang berbeda, definisi temporal harus diperjelas.
- Hasil model hanya dapat digeneralisasikan pada populasi dan periode yang representatif terhadap data penelitian.

21. Kesimpulan Rancangan Penelitian

Rancangan final menggunakan NPL sebagai outcome binary dan delapan kandidat variabel independen: (1) kondisi_name/kepemilikan STNK, (2) pekerjaan, (3) merk, (4) usia kendaraan, (5) pajak, (6) pinjaman_pokok_awal, (7) Itv_max, dan (8) zona_ltv.

Binary logistic regression menjadi metode inferensial utama. Analisis dilakukan bertingkat dari data audit, validasi outcome, descriptive, bivariat, model inti, model dengan Itv_max, model dengan zona_ltv, dan full candidate model bila layak. Model dievaluasi menggunakan goodness-of-fit, AIC/BIC, discrimination, calibration, multicollinearity, dan sensitivity analysis.

Secara metodologis, Itv_max dan zona_ltv diperlakukan sebagai kandidat representasi LTV yang perlu diuji, bukan dipaksakan masuk secara bersamaan. Keputusan final harus mengikuti definisi bisnis dan hasil diagnostic. Fokus utama penelitian adalah menghasilkan estimasi asosiasi yang dapat dipertanggungjawabkan dan, bila tujuan diperluas, menjadi fondasi pengembangan risk scoring yang tidak mengalami data leakage.

Checklist sebelum analisis final:

- Tetapkan cut-off date.
- Validasi formula NPL terhadap kolom NPL aktual.
- Audit duplicate dan unit analisis.
- Audit missing terutama pekerjaan.
- Audit kategori rare.
- Audit distribusi Itv_max dan zona_ltv.
- Pastikan definisi LTV dan Itv_max jelas.
- Periksa hubungan LTV-Itv_max-zona_ltv.
- Tetapkan reference category.
- Jalankan Model 0-4.
- Periksa multikolinearitas, linearitas logit, dan separation.
- Evaluasi AIC/BIC, AUC/PR-AUC, calibration dan Brier.
- Lakukan sensitivity analysis.
- Baru tetapkan model final dan interpretasi bisnis.